PUC Minas

Pontifícia Universidade Católica de Minas Gerais
ICEI - Departamento de Ciência da Computação
Disciplina: Compiladores
Prof. Alexei Machado

Trabalho Prático

A construção de um compilador para uma linguagem imperativa simplificada

Objetivo

O objetivo do trabalho prático é o desenvolvimento de um compilador completo que traduza programas escritos na linguagem fonte "L" para um subconjunto do ASSEMBLY da família 80x86. Ambas as linguagens serão descritas durante o semestre. Ao final do trabalho, o compilador deve produzir um arquivo texto que possa ser convertido em linguagem de máquina pelo montador MASM e executado com sucesso em um processador real. No caso do programa conter erros, o compilador deve reportar o primeiro erro e terminar o processo de compilação. **O formato das mensagens de erro será especificado posteriormente e deverá ser rigorosamente observado. O programa executável do compilador deve se chamar "LC" e receber 2 parâmetros da linha de comando (argumentos): o nome completo do programa fonte a ser compilado (extensão .L) e o nome completo do programa ASSEMBLY (extensão .ASM) a ser gerado.**

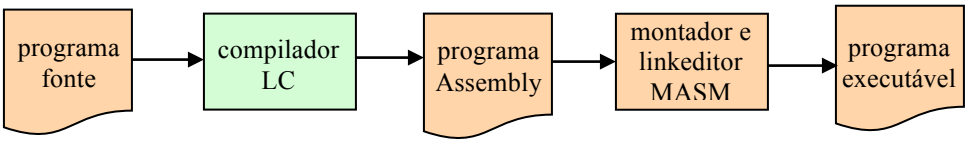

Definição da Linguagem-Fonte L

A linguagem "L" é uma linguagem imperativa simplificada, com características do C e Pascal. A linguagem oferece tratamento para 2 tipos básicos explícitos: *char* e *integer,* além do tipo lógico que é implícito. O tipo *char* é um escalar que varia de 0 a 255, podendo ser escrito em formato alfanumérico ou hexadecimal. Constantes em formato hexadecimal são da forma 0xDD, onde DD é um número hexadecimal. Constantes em formato alfanumérico são da forma 'c' onde c é um caractere imprimível. O tipo *integer* é um escalar que varia de –32768 a 32767, ocupando 2 bytes. Além dos tipos básicos a linguagem permite a definição de vetores unidimensionais de caracteres e inteiros, com até 4kbytes. Um *string* é um vetor de caracteres que quando armazenado em memória, tem seu conteúdo útil finalizado pelo caracter '$'. Constantes que representam strings são delimitadas por aspas e não devem conter aspas, quebra de linha ou $. Entretanto, esses caracteres são permitidos nos vetores de caracteres. Dessa forma, vetores e strings são compatíveis entre si, ficando a cargo do programador o controle dos seus conteúdos e tamanhos. tipo lógico assume valores 0 (falso) e 1 (verdadeiro), ocupando um byte de memória.

Os caracteres permitidos em um arquivo fonte são as letras, dígitos, espaço, sublinhado, ponto, vírgula, ponto-e-vírgula, e_comercial, dois-pontos, parênteses, colchetes, chaves, mais, menos, aspas, apóstrofo, barra, porcentagem, circunflexo, arroba, exclamação, interrogação, maior, menor e igual, além da quebra de linha (bytes 0Dh e 0Ah). Qualquer outro caractere é considerado inválido.

Os identificadores de constantes e variáveis são compostos de letras, dígitos, sublinhado e ponto, não podem começar com dígitos, nem conter apenas sublinhados ou pontos, e têm no máximo 255 caracteres. Maiúsculas e minúsculas não são diferenciadas.

As seguintes palavras e suas variações com maiúsculas e minúsculas são reservadas:

const	var	integer	char	for	if
else	and	or	not	=	to
(	)	<	>	<>	>=
<=	,	+	-	*	/
;	{	}	then	readln	step
write	writeln	%	[	]	do

Os comandos existentes em "L" permitem atribuição a variáveis através do operador =, entrada de valores pelo teclado e saída de valores para a tela, estruturas de repetição (repita para), estruturas de teste (se - então - senão), expressões aritméticas com inteiros e caracteres, expressões lógicas e relacionais, manipulação de vetores, além de atribuição e comparação de igualdade entre strings. A ordem de precedência nas expressões é:

a) parênteses;
b) negação lógica (not);
c) multiplicação aritmética (*) e lógica (and), quociente da divisão (/) e resto da divisão (%);
d) subtração (-), adição aritmética (+) e lógica (or);
e) comparação aritmética (=,<>,<,>,<=,>=) e entre strings (=).

Comentários são delimitados por /* */. A quebra de linha e o espaço podem ser usados livremente como delimitadores de lexemas.

A estrutura básica de um programa-fonte é da forma:

Declarações Bloco_de_Comandos fim_arquivo

A seguir, é feita a descrição informal da sintaxe das declarações e comandos da linguagem:

1. Declaração de variáveis: inicia-se pela palavra reservada *Var*, à qual seguem-se uma ou mais listas de declarações da forma: *tipo lista-de-ids;* , onde *tipo* pode ser *integer* ou *char* e *lista-de-ids* é uma série de 1 ou mais identificadores de escalares ou vetores, separados por vírgulas. Variáveis escalares podem ser opcionalmente inicializadas na

forma: *id = valor* , onde *id* é um identificador. Para inteiros, *valor* é uma constante decimal precedida ou não de sinal negativo; Para caractere, uma constante hexadecimal ou alfanumérica. Declarações de vetores são da forma *id[tam]*, onde tam é uma constante inteira maior que 0. O tamanho em bytes de um vetor não pode ultrapassar 4Kbytes. Vetores não podem ser inicializados na declaração.

2. Declaração de constantes escalares: é da forma: *const id = valor;* , onde *id* é um identificador e *valor* uma constante numérica, precedida ou não de sinal negativo, hexadecimal ou caractere alfanumérico.

3. Comando de atribuição: é da forma *id = expressão;* ou *id[expressão] = expressão;*

4. Comando de repetição: pode assumir duas formas:

   For id=expressão to expressão step constante do comando
   For id=expressão to expressão step constante do { comandos }

   onde *expressão* e *constante* são do tipo inteiro e *comandos* é uma lista de zero ou mais comandos da linguagem. A definição de step é opcional, sendo 1 se não estiver especificada.

5. Comando de teste: pode assumir as formas, onde *expressão* é do tipo lógico:

   if expressão then comando1
   if expressão then comando1 else comando2

   comando1 e/ou *comando2* podem ser independentemente substituídos por blocos da forma:

   if expressão then { lista_comandos1 } else { lista_comandos2 }

   onde as listas são sequências de comandos.

6. Comando nulo: é da forma *;* . Nada é executado neste comando.

7. Comando de leitura: é da forma *readln(id);* , onde *id* é um identificador de variável inteira, caractere alfanumérico ou string. Caracteres e strings são lidos da mesma maneira, sem que o usuário precise coloca-los entre aspas ou apóstrofos. Números inteiros podem ter sinal negativo.

8. Comandos de escrita: são da forma *write(lista_expressões);* ou *writeln(lista_expressões);* ,onde *lista_expressões* é uma lista de uma ou mais expressões inteiras, caracteres ou strings, separadas por vírgulas. A última forma, quando executada, causa a quebra de linha após a impressão.

PUC Minas

Pontifícia Universidade Católica de Minas Gerais
ICEI - Departamento de Ciência da Computação
Disciplina: Compiladores
Prof. Alexei Machado

Considerações gerais para todas as práticas:

1. O trabalho deverá ser feito em grupos de dois ou três alunos, sem qualquer participação de outros grupos e/ou ajuda de terceiros. Cada aluno deve participar ativamente em todas as etapas do trabalho. Os componentes dos grupos devem ser informados em um prazo de 2 semanas, através de e-mail para alexeimcmachado@gmail.com e não poderão ser alterados durante o semestre. Os alunos que não tiverem feito grupos até esta data serão agrupados pelo professor de maneira arbitrária, em grupos de 2 ou 3 alunos.

2. A codificação do trabalho deve ser feita em linguagem C, C++ ou Java, **EXCLUSIVAMENTE em ambiente WINDOWS**. Os arquivos enviados devem poder ser compilados **sem necessidade de arquivos de projeto específicos de IDEs**. Não poderão ser utilizados bibliotecas gráficas ou qualquer recurso que não esteja instalado oficialmente nos laboratórios do ICEI.

3. O trabalho será avaliado em 2 etapas:
   a) as práticas TP1 e TP2 (10 pontos), em uma única versão final, deverão ser postadas no SGA até às 08:00 horas do dia 08/04/2010, juntamente com a documentação, e apresentadas conforme o cronograma. O atraso na entrega implicará em perda de 3 pontos por dia.
   b) as práticas TP3 e TP4 (15 pontos), em uma única versão final, deverão ser postadas no SGA até às 08:00 horas do dia 05/06/2017, juntamente com a documentação, e apresentadas conforme o cronograma. **Para esta etapa não se admite atraso, ou seja, não serão avaliados trabalhos entregues após 05/06.**

4. Os trabalhos devem ser postados na forma de um arquivo compactado com software disponível no laboratório, com **tamanho máximo de 3MB**, e seu nome deve ser o número de matrícula de um dos componentes (Ex:346542.zip). **Os arquivos fontes devem estar no diretório raiz** e devem conter o nome de todos os componentes do grupo no início do código.

5. **Trabalhos iguais, na sua totalidade ou em partes, copiados, "encomendados" ou outras barbaridades do gênero, serão severamente penalizados. É responsabilidade do aluno manter o sigilo sobre seu trabalho, evitando que outros alunos tenham acesso a ele. No caso de cópia, ambos os trabalhos serão penalizados, independentemente de quem lesou ou foi lesado no processo.**

6. Será pedida ao Colegiado uma advertência formal no caso de cópia por má fé.

7. Durante a apresentação poderão ser feitas perguntas relativas ao trabalho, as quais serão consideradas para fim de avaliação. Todos os componentes devem comparecer e serem

capazes de responder a **quaisquer perguntas e/ou alterar o código de qualquer parte do trabalho**. A avaliação será individual.

8. É fundamental que a especificação do trabalho seja **rigorosamente obedecida**, principalmente com relação à **interface com o usuário**, uma vez que parte da correção será automatizada. Observe principalmente qual deve ser o **nome** do programa executável, seus argumentos de entrada e formatos das mensagens. Trabalhos com interfaces diferentes das especificadas correm o risco de **não serem avaliadas.**

9. A avaliação será baseada nos seguintes critérios:
   - Correção e robustez dos programas
   - Conformidade às especificações
   - Clareza de codificação (comentários, endentação, escolha de nomes para identificadores)
   - Organização dos arquivos do projeto
   - Parametrização
   - Apresentação individual
   - Documentação